



FACULTÉ DES SCIENCES DHAR EL MAHRAZ
UNIVERSITÉ SIDI MOHAMED BEN ABDELLAH

Filière : sciences mathématiques et informatiques

Projet Tutoré (S6)

Mémoire

Intitulé : Segmentation et détection des images aériennes

Présenté par : Echibi Rajae et El hadri Aya

Encadrant : Pr. RIFFI Jamal

Soutenu le : Jeudi 29 mai 2025

Jury composé de :

Examineur 1 : Pr. Khalid El Fazazy

Examineur 2 : Pr. Ilyass Aboussaleh

Examineur 3 : Pr. Sabri My Abdelouahed

Examineur 4 : Pr. Mohammed Adnane Mahraz

Examineur 5 : Pr. Hamid Tairi

Examineur 6 : Pr. Ali Yahyaoui

Examineur 7 : Pr. EL Batteoui Ismail



Filière des Sciences
Mathématiques et Informatique
Pr. MAHRAZ Mohammed Adnane

Année Universitaire : 2024/2025

Remerciement

C'est une tâche très agréable, mais bien délicate, de présenter nos remerciements à tous ceux qui nous ont soutenus dans la réalisation de ce travail.

Avant tout, nous adressons nos louanges à **Allah**, le Tout-Puissant et Miséricordieux, qui nous a donné la force, la patience et la santé nécessaires pour mener à bien ce modeste travail, ainsi que ces années d'études.

Nous exprimons ensuite notre profonde gratitude à notre encadrant, Pr. RIFFI Jamal, pour son accompagnement tout au long de ce projet. Sa disponibilité, ses conseils avisés, sa bienveillance et son expertise ont été d'une grande richesse et ont fortement contribué à la réussite de ce travail. Nous avons particulièrement apprécié la qualité de ses enseignements ainsi que ses orientations précieuses à chaque étape du projet.

Nous tenons également à remercier chaleureusement **nos amis**, pour leur soutien moral constant, leur motivation et leur précieuse aide, que ce soit à travers des conseils, des échanges constructifs, ou tout simplement leur présence bienveillante dans les moments difficiles. Leur encouragement a été un véritable moteur pour avancer et mener à bien ce projet.

Enfin, nous remercions les membres du jury pour le temps consacré à l'évaluation de notre travail, ainsi que l'ensemble du corps professoral et administratif de la **Faculté des Sciences Dhar El Mahraz – Fès**, en particulier les enseignants du département d'informatique, pour leur accompagnement tout au long de notre parcours en Licence.

Résumé

Ce projet vise à exploiter l'intelligence artificielle pour la détection et la segmentation automatique d'objets à partir d'images satellites et images drones, en utilisant des modèles d'apprentissage profond. L'objectif principal est d'analyser, cartographier et classifier des éléments géospatiaux tels que les routes, les bâtiments ou la végétation à l'aide de modèles performants comme YOLOv8, U-Net et Mask R-CNN.

Après avoir collecté et annoté des données issues de plateformes comme Kaggle (images satellites) et Roboflow (images drones), nous avons entraîné ces modèles sur des tâches spécifiques : YOLOv8 pour la détection d'objets en temps réel, U-Net pour la segmentation sémantique pixel par pixel, et Mask R-CNN pour la segmentation d'instance.

Les résultats obtenus ont montré que :

- YOLOv8 est rapide et efficace pour la détection d'objets distincts sur les images drones.
- U-Net excelle dans la segmentation sémantique sur les images satellites avec des surfaces homogènes.
- Mask R-CNN, bien qu'utilisé hors de sa configuration classique, a produit des masques précis pour des scènes complexes.

Les performances ont été évaluées avec les métriques IoU et Dice coefficient, permettant de juger la qualité des segmentations. Le projet met en lumière la complémentarité des images drones et satellites ainsi que des modèles IA pour des applications telles que la cartographie urbaine, l'agriculture de précision et la surveillance environnementale.

Des pistes d'amélioration sont proposées, notamment l'intégration de modèles plus avancés comme SAM ou Mask2Former, l'enrichissement des données et l'utilisation de capteurs supplémentaires.

Liste des Figures

Figure 1 : Utilisation combinée des images satellites, des drones et de l'intelligence artificielle pour une gestion intelligente de l'espace.....	10
Figure 2: Différence entre Classification et Régression	14
Figure 3: Apprentissage Automatique et Apprentissage Profond.....	16
Figure 4 : Les types de fonctions de transfert utilisées dans les réseaux de neurone artificiels.....	19
Figure 5 : Les couches d'un réseau de neurone artificiel.....	22
Figure 6: Carte conceptuelle des réseaux de neurones artificiels.....	25
Figure 7: Réseaux de neurones multicouches.....	26
Figure 8 : Architecture du CNN.....	27
Figure 9 : Illustration de la couche de convolution dans un CNN.....	28
Figure 10: Max pooling avec un filtre 3 x 3.....	29
Figure 11: Illustration de la couche ReLU.....	29
Figure12 :illustration de satellite et imagerie satellitaire.....	32
Figure13 :Drone et exemple d' Image.....	35
Figure 14 :différence entre sémantique et instance.....	41
Figure 15 :illustration de différence entre segmentation et détection.....	42
Figure 16 : Image utilisée pour Mask R-CNN.....	55
Figure 17 : Image utilisée pour U-Net	55
Figure 18 : Images utilisées pour YOLOv8.....	56
Figure 19 : image prise par drone.....	65
Figure 20 : Détection avec YOLOv8 sur l' image.....	65
Figure 21 :image prise par satellite.....	66
Figure 22 : Résultat YOLOv8 sur l' image.....	66
Figure 23 : Résultat de segmentation sémantique avec Mask R-CNN sur image drone.....	67
Figure 24 :Résultat U-Net sur image satellite du dataset.....	68
Figure 25 :Résultat U-Net sur image drone du dataset	68

Liste des Acronymes

- IA : Intelligence Artificielle
- SVM : Support Vector Machine (Machine à Vecteurs de Support
- CNN : Convolutional Neural Network (Réseau de Neurones Convolutifs)
- ReLu : Rectified Linear Unit
- RGB : Red-Green-Blue (couleurs d'image)
- RPN : Region Proposal Network
- RoI : Region of Interest
- YOLO : You Only Look Once.
- YOLOvx : You Only Look Once Version; $x = \{1, 2, 3, \dots, 8\}$.
- IoU : Intersection over Union
- QGIS : Quantum GIS (logiciel SIG)
- SAM : Segment Anything Model
- FPN : Feature Pyramid Network
- GPU : Graphics Processing Unit
- CPU : Central Processing Unit
- PIL : Python Imaging Library (via Pillow)
- COCO : Common Objects in Context (format d'annotation)
- NTIC : Nouvelles Technologies de l'Information et de la Communication

Table de matières

Chapitre I. Intelligence Artificielle	12
Introduction :	12
1.Apprentissage automatique (Machine Learning) :	12
1.1 Apprentissage non supervisé :	13
1.2 Apprentissage supervisé :	13
1.3 Classification :	13
1.4 Régression :	14
1.5 Les domaines d'application de l'apprentissage automatique :	14
2.Apprentissage profond (Deep learning) :	15
2.1 Domaines d'application de l'apprentissage profonde :	16
3.Les réseaux de neurones :	17
3.1 Introduction :	17
3.2 Histoire :	17
3.3 Utilisation des réseaux de neurones :	18
3.4 Fonction d'activation :	19
3.5 Le biais :	19
3.6 Propagation avant :	21
3.7 La rétropropagation :	22
3.8 Fonction d'erreur :	23
3.9 Algorithme de descente du gradient :	24
3.10 Les types des réseaux de neurones :	25
3.11 L'entraînement d'un réseau de neurones profonds :	26
4.Les réseaux de neurones convolutifs (CNN) :	27
4.1 Définition :	27
4.2 Couche de convolution :	28
4.3 Rembourrage :	29
4.4 Non-linéarité (ReLU) :	29
4.5 Couche de mise en commun :	30
4.6 Couche entièrement connectée :	30

Conclusion	30
Chapitre II : Présentation des images satellitaires et drones.....	32
Introduction :.....	32
1.Les images satellites :.....	32
1.1 Définition :.....	32
1.1 Types de satellites (Sentinel, Landsat, SPOT...) :.....	32
1.2 Types d'images (optique, radar, multispectrale) :.....	33
1.3 Caractéristiques techniques :.....	33
1.4 Domaines d'utilisation (agriculture, environnement, cartographie...) :.....	34
2.Les images drones :.....	34
2.1 Définition :.....	34
2.2 Types de drones (multirotors, aile fixe...) :.....	35
2.3 Capteurs embarqués (RGB, multispectral, thermique...) :.....	35
2.4 Avantages du drone :	35
2.5 Domaines d'application (inspection, modélisation 3D, suivi de projet...) :.....	36
3.Comparaison entre les images satellites et les images drones :.....	36
3.1 Résolution (spatiale, temporelle) :.....	36
3.2 Couverture et accessibilité :.....	37
3.3 Coût et logistique :	37
3.4 Adaptation selon le type de projet :.....	37
3.5 Avantages et inconvénients de chaque source :.....	37
Conclusion :	37
Chapitre III. Modèles de détection et de segmentation d'objets	39
Introduction :.....	39
1.Tâches fondamentales d'analyse d'image : détection et segmentation :.....	39
1.1Détection d'objets :.....	39
1.2.Segmentation d'images :.....	40
1.3 Différence entre détection et segmentation :	41
2.Modèles de détection et segmentation :.....	42
2.1 YOLO :.....	42
2.2 U-Net :	47
2.3.Mask R-CNN :.....	49
Conclusion :	51

CHAPITRE IV. Classification et Segmentation des images satellitaires et Drones	52
Introduction.....	52
1.Zone d'étude et Données utilisées :	54
1.1 Présentation de la zone géographique analysée :	54
1.2 Sources des données (images satellite & drone) :	56
1.3 Annotation et préparation des données pour l'entraînement :	56
1.3 Paramètres des données d'entraînement par modèle :	57
2.Environnement de travail et outils utilisés :	58
2.1 Bibliothèques et frameworks (PyTorch, Ultralytics, etc.) :	58
2.2 Outils d'annotation et traitement (LabelImg, Roboflow, QGIS...) :	61
2.3 Configuration matérielle et logicielle :	62
3.Mise en œuvre des modèles de détection et segmentation :	63
3.1Choix et paramétrage des modèles YOLOv8, U-Net, Mask R-CNN :	63
3.2 Méthodologie d'entraînement et validation croisée :	64
3.3 Adaptation aux caractéristiques des images satellites et drones :	64
4.Résultats et Évaluation :	65
4.1 Résultats par modèle et par type d'image :	65
4.1.1 YOLOv8 – Détection sur images drone et satellite.....	65
4.1.3 Mask R-CNN – Segmentation sémantique sur image drone	66
4.1.3 U-Net – Segmentation sémantique sur images satellites	67
Conclusion et Perspectives :	70

Introduction Générale

Depuis les premières observations de la Terre depuis l'espace, l'imagerie satellite et l'acquisition d'images aériennes ont révolutionné notre compréhension de l'environnement et du territoire. Avec l'arrivée des drones, la télédétection a connu un nouvel essor, offrant des images à très haute résolution, disponibles à la demande, et adaptables à divers besoins d'analyse. Ces technologies, en constante évolution, trouvent aujourd'hui des applications variées dans les domaines de l'urbanisme, de l'agriculture, de l'écologie, de la cartographie ou encore de la gestion des risques naturels.

Parallèlement, les avancées fulgurantes de l'intelligence artificielle (IA), en particulier dans le domaine du deep learning, permettent désormais de traiter et d'interpréter automatiquement ces images massives. L'IA ouvre la voie à des systèmes capables de détecter, segmenter et classer automatiquement les objets présents dans des images satellites ou captées par drone, avec une précision et une efficacité sans précédent.

L'intégration de ces deux domaines — la vision par ordinateur et la télédétection — constitue le cœur de notre projet. En exploitant des images issues de satellites (comme Sentinel-2) et de drones (à partir de plateformes comme Roboflow), nous avons mis en œuvre et comparé plusieurs modèles d'apprentissage profond, notamment YOLOv8, U-Net et Mask R-CNN. Ces modèles ont été appliqués à des tâches de détection d'objets et de segmentation sémantique ou d'instance, dans le but de cartographier et classer automatiquement les éléments géospatiaux présents sur les images (routes, bâtiments, végétation, etc.).




Figure 1 : Utilisation combinée des images satellites, des drones et de l'intelligence artificielle pour une gestion intelligente de l'espace

Les objectifs de ce projet sont multiples :

- Exploiter et prétraiter des images satellites et drones issues de bases de données ouvertes.
- Mettre en œuvre des architectures de deep learning pour la détection et la segmentation d'objets.
- Comparer les performances des modèles sur des métriques précises comme l'IoU ou le Dice coefficient.
- Discuter des limites actuelles et des perspectives futures pour l'amélioration de ces systèmes.

Dans ce rapport, nous aborderons plusieurs chapitres structurés pour présenter notre projet de manière exhaustive :

- **Chapitre I : Intelligence Artificielle**

Ce chapitre introduit les concepts fondamentaux de l'IA, en particulier l'apprentissage automatique et l'apprentissage profond. Nous y présentons les réseaux de neurones, les réseaux convolutifs (CNN), ainsi

que les approches de classification et de régression utilisées dans le traitement d'images.

- **Chapitre II : Présentation des Images satellitaires et Drones**

Nous détaillerons les caractéristiques des images issues de satellites et de drones, en comparant leur résolution, leur mode d'acquisition et leurs domaines d'application.

- **Chapitre III : Modèles de Détection et de Segmentation**

Ce chapitre sera dédié à la présentation technique des modèles utilisés : YOLOv8, U-Net et Mask R-CNN. Nous expliquerons leur fonctionnement, leurs spécificités, ainsi que leurs versions respectives.

- **Chapitre IV : Mise en œuvre sur Données Réelles**

Cette partie décrira les données utilisées, l'environnement logiciel, les outils d'annotation, et le processus complet d'entraînement, validation et test. Nous analyserons ensuite les résultats obtenus pour chaque modèle et discuterons des performances, des avantages et des limites identifiées.

Cette structure nous permettra de couvrir l'ensemble des aspects techniques, scientifiques et applicatifs de notre projet, tout en mettant en lumière l'apport crucial de l'intelligence artificielle dans le traitement des données géospatiales issues de la télédétection moderne.

Chapitre I. Intelligence Artificielle

Introduction :

L'intelligence artificielle (IA) est un domaine en constante évolution qui révolutionne notre manière de penser, de travailler et d'interagir avec le monde qui nous entoure. En son essence, l'IA vise à doter les machines de capacités similaires à celles de l'intelligence humaine, telles que l'apprentissage, la résolution de problèmes, la perception et le langage. Ce domaine interdisciplinaire englobe une multitude de techniques et de méthodes, dont le machine learning, le deep learning, les réseaux de neurones et bien d'autres. L'IA trouve des applications dans une grande variété de domaines, notamment la santé, les finances, les transports, la robotique, les jeux et bien sûr, l'agriculture. Son potentiel est immense, offrant des opportunités sans précédent pour innover et résoudre des défis complexes à l'échelle mondiale.

1.Apprentissage automatique (Machine Learning) :

D'une manière générale, l'apprentissage humain est un processus adaptatif par lequel l'individu fournit des réponses adéquates à certaines situations. L'apprentissage automatique est un domaine de l'intelligence artificielle (IA) dont l'objectif est d'étudier les moyens par lesquels une machine peut apprendre de manière autonome à effectuer une tâche ou à faire des prédictions à partir de données. Cela signifie que, dans un premier temps, il faut lui fournir des données et dans un second temps, elle peut faire des associations. Cet apprentissage est réalisé par des outils qui permettent d'acquérir, d'élargir et d'améliorer les connaissances dont dispose le système. Les chercheurs travaillent sans relâche pour faire du Machine Learning une réalité. Cette réalité consiste à "enseigner" aux ordinateurs comment apprendre comme les humains afin de progresser vers ce que certains considèrent comme la prochaine révolution technologique : des machines qui pensent comme l'Homme.

C'est exactement comme le fait regarder un bébé essayer de dire ses premiers mots incompréhensibles pendant des mois. Puis un jour, inexplicablement, le mot "maman" sort. En poursuivant l'analogie avec le bébé, celui-ci continuera à apprendre d'autres mots et à comprendre leur signification. De la même manière,

le Deep Learning apprend en permanence. Il veut arriver à un point où il alimente certaines informations et sait automatiquement quoi en faire.

On distingue plusieurs types d'apprentissage en Machine Learning. En général, ils peuvent être répartis en deux types : supervisés et non supervisés.

1.1 Apprentissage non supervisé :

Dans le cas de l'apprentissage non supervisé, on ne donne pas d'exemples de résultats attendus. Seules les données d'entrée sont fournies et le système doit apprendre, de façon autonome, la meilleure façon d'explorer les données. Il doit chercher à identifier dans le jeu de données une façon de les structurer (trouver des modèles) ou encore à extraire des caractéristiques particulières. Il propose ainsi des réponses à partir d'analyses et de groupement de données.

1.2 Apprentissage supervisé :

Dans l'apprentissage supervisé comme dans l'apprentissage non supervisé, tout commence par une très grande base de données, et c'est à partir de cette base que l'algorithme peut apprendre. Mais dans l'apprentissage supervisé, la machine connaît déjà les réponses qu'elle est censée donner. Elle travaille à partir de données étiquetées. Prenons notre projet de détection conçue pour reconnaître automatiquement les oranges pourries. Pour l'entraîner, on lui présente des courriels étiquetés comme " fraîche " ou " pourrie ". À l'aide de techniques issues des statistiques et des probabilités, l'algorithme comprend alors quelles caractéristiques lui permettent de classer ces courriels dans chaque catégorie. Ainsi, lorsqu'on lui présente de nouveaux oranges, il sera capable de les identifier, en leur attribuant un score de probabilité, par exemple : Cet orange a 95% de chances d'être un pourrie. Ainsi ses premières réponses seront corrigées, afin qu'il puisse s'améliorer au fur et à mesure.

Cette méthode est couramment utilisée par la régression et la classification.

1.3 Classification :

Il utilise un algorithme pour attribuer avec précision les données de test dans des catégories spécifiques. Il reconnaît des entités spécifiques au sein de l'ensemble de données et tente de tirer des conclusions sur la façon dont ces entités doivent être étiquetées ou définies. Les algorithmes de classification courants sont les

classificateurs linéaires, les machines à vecteurs de support (SVM), les arbres de décision, le k plus proche voisin et la forêt aléatoire.

1.4 Régression :

Il est utilisé pour comprendre la relation entre les variables dépendantes et indépendantes. Il est couramment utilisé pour faire des projections, par exemple pour le chiffre d'affaires d'une entreprise donnée. La régression linéaire, la régression logistique et la régression polynomiale sont des algorithmes de régression populaires.

La différence entre la classification et la régression :

- On utilise la régression pour prédire une valeur numérique telle qu'un pourcentage ou une valeur absolue. La variable de sortie est alors une valeur réelle.
- La classification, en revanche, serait utilisée pour fournir une réponse qualitative la variable de sortie est donc une catégorie.




Figure 2: Différence entre Classification et Régression

1.5 Les domaines d'application de l'apprentissage automatique :

Les domaines d'application de l'apprentissage automatique sont vastes et en constante expansion, touchant pratiquement tous les aspects de notre vie quotidienne. Dans le domaine de la santé, par exemple, l'apprentissage automatique est utilisé pour analyser des données médicales complexes, aider au diagnostic précoce des maladies, personnaliser les traitements et prédire les résultats des patients. Dans le secteur financier, il est employé pour détecter la fraude, anticiper les fluctuations du marché et optimiser les portefeuilles d'investissement. Les applications de l'apprentissage automatique dans les

transports incluent la conduite autonome, la planification des itinéraires et l'optimisation du trafic. Dans le domaine de la sécurité, il est utilisé pour la détection d'intrusions, l'analyse des menaces et la prévention des cyberattaques. En outre, l'apprentissage automatique trouve des applications dans la recommandation de contenus personnalisés sur les plateformes en ligne, la reconnaissance vocale et faciale, la traduction automatique, et même la création artistique. Ces exemples illustrent la polyvalence et l'impact profond de l'apprentissage automatique dans de nombreux domaines, façonnant ainsi notre société de manière significative.

2.Apprentissage profond (Deep learning) :

L'intelligence artificielle est une discipline scientifique recherchant des méthodes de solution de problèmes à forte complexité logique ou algorithmique. L'apprentissage automatique champ d'étude de l'intelligence artificielle. Par conséquent, L'apprentissage profond (en anglais deep learning, deep structured learning, hierarchical learning) est un ensemble de méthodes d'apprentissage automatique tentant de modéliser avec un haut niveau d'abstraction des données grâce à des architectures articulées de différentes transformations non linéaires. Dans ce chapitre nous allons présenter tout d'abord les notions en relation avec l'apprentissage profond.

L'apprentissage profond (« deep learning ») est un ensemble de techniques d'apprentissage automatique qui a permis des avancées importantes en intelligence artificielle dans les dernières années. Dans l'apprentissage automatique, un programme analyse un ensemble de données afin de tirer des règles qui permettront de tirer des conclusions sur de nouvelles données. L'apprentissage profond est basé sur ce qui a été appelé, par analogie, des « réseaux de neurones artificiels », composés de milliers d'unités (les « neurones ») qui effectuent chacune de petites opérations simples. Les résultats d'une première couche de « neurones » servent d'entrée aux calculs d'une deuxième couche et ainsi de suite. Par exemple, pour la reconnaissance visuelle, des premières couches d'unités identifient des lignes, des courbes, des angles... des couches supérieures identifient des formes, des combinaisons de formes, des objets, des contextes... Les progrès de l'apprentissage profond ont été possibles

notamment grâce à l'augmentation de la puissance des ordinateurs et au développement de grandes bases de données (« big data »).




Figure 3: Apprentissage Automatique et Apprentissage Profond

L'apprentissage profond est un sous-domaine de l'apprentissage automatique qui traite d'algorithmes inspirés de la structure et de la fonction du cerveau appelés réseaux de neurones artificiels. En d'autres termes, il reflète le fonctionnement de notre cerveau. Les algorithmes d'apprentissage profond sont similaires à la façon dont le système nerveux a structuré où chaque neurone se connecte et transmet des informations.

Le deep Learning s'appuie sur un réseau de neurones artificiels s'inspirant du cerveau humain. Ce réseau est composé de dizaines voire de centaines de « couches » de neurones, chacune recevant et interprétant les informations de la couche précédente. Le système apprendra par exemple à reconnaître les lettres avant de s'attaquer aux mots dans un texte, ou détermine s'il y a un visage sur une photo avant de découvrir de quelle personne il s'agit.

2.1 Domaines d'application de l'apprentissage profonde :

Ces techniques se développent dans le domaine de l'informatique appliquée aux NTIC (reconnaissance visuelle — par exemple d'un panneau de signalisation par un robot ou une voiture autonome — et vocale notamment) à la robotique, à la bio-informatique, la reconnaissance ou comparaison de formes, la sécurité, la santé, etc..., la pédagogie assistée par l'informatique, et plus généralement à l'intelligence artificielle. L'apprentissage profond peut par exemple permettre à

un ordinateur de mieux reconnaître des objets hautement déformables et/ou analyser par exemple les émotions révélées par un visage photographié ou filmé, ou analyser les mouvements et position des doigts d'une main, ce qui peut être utile pour traduire le langage des signes, améliorer le positionnement automatique d'une caméra, etc... Elles sont utilisées pour certaines formes d'aide au diagnostic médical (ex. : reconnaissance automatique d'un cancer en imagerie médicale), ou de prospective ou de prédiction (ex. : prédiction des propriétés d'un sol filmé par un robot).

L'apprentissage profond est un sous-domaine de l'apprentissage automatique qui traite d'algorithmes inspirés de la structure et de la fonction du cerveau appelés réseaux de neurones artificiels. En d'autres termes, il reflète le fonctionnement de notre cerveau. Les algorithmes d'apprentissage profond sont similaires à la façon dont le système nerveux a structuré où chaque neurone se connecte et transmet des informations.

3. Les réseaux de neurones :

3.1 Introduction :

Les réseaux neuronaux constituent un modèle d'apprentissage automatique révolutionnaire, s'inspirant du fonctionnement du cerveau humain. Contrairement aux systèmes informatiques traditionnels, ils apprennent automatiquement des associations entre les données d'entrée et de sortie, et peuvent traiter une grande variété de formats, comme les images, le texte et l'audio. Cette capacité à s'adapter et à apprendre leur confère une puissance et une polyvalence uniques, faisant d'eux l'un des outils les plus avancés de l'apprentissage automatique moderne.

3.2 Histoire :

Étonnamment, les réseaux de neurones artificiels existent depuis un certain temps déjà. Ils ont été présentés pour la première fois en 1943 par le neurophysiologiste Warren McCulloch et le mathématicien Walter Pitts. Dans leur article "A Logical Calculus of Ideas Immanent in Nervous Activity," et ont ensuite développé un modèle simplifié du fonctionnement des neurones biologiques. Cependant, dans les années 1970 et 1980, les réseaux de neurones

se sont très peu développés car, dès 1969, certains scientifiques avaient mis en évidence leurs limites conceptuelles. Une révolution s'est produite en 1986 dans le domaine des réseaux neuronaux artificiels avec de nouvelles générations de réseaux neuronaux (capables de traiter avec succès des phénomènes non linéaires) comme le perceptron multicouche et l'apparition de l'algorithme de rétropropagation d'erreur publié par Rumelhart, Hinton et Williams qui permet d'optimiser les paramètres d'un réseau neuronal multicouche, ainsi la recherche sur les réseaux neuronaux a démarré fortement, impliquant le succès de cette méthode et son application dans divers domaines.

Par la suite, la recherche sur les réseaux de neurones artificiels s'est considérablement développée. Grâce aux progrès mentionnés ci-dessus, mais aussi au développement de l'informatique. L'augmentation de la puissance de calcul a en effet permis d'appliquer diverses théories et de les utiliser dans de nombreux domaines.

3.3 Utilisation des réseaux de neurones :

Les réseaux neuronaux ont une capacité remarquable à donner un sens, extraire des règles et des tendances à partir de données compliquées. Ils peuvent être utilisés pour extraire des modèles et détecter des tendances basées sur des fonctions mathématiques compliquées qui sont trop difficiles ou impossibles à modéliser à l'aide de techniques analytiques ou paramétriques traditionnelles. L'une des propriétés intéressantes des réseaux neuronaux est qu'ils peuvent prédire avec précision des données qui ne faisaient pas partie des données d'apprentissage. Compte tenu de ces caractéristiques et de leur large éventail d'applications, les réseaux neuronaux sont particulièrement bien adaptés à l'application de problèmes du monde réel dans la recherche scientifique, commerciale et industrielle. On trouve un certain nombre de domaines dans lesquels les réseaux neuronaux ont été appliqués avec succès.

- Traitement du signal
- Contrôle des processus
- La robotique
- La classification

- Prétraitement des données - Reconnaissance des formes
- Analyse d'images et synthèse vocale
- Diagnostic et suivi médical

3.4 Fonction d'activation :

La fonction d'activation est une fonction qui est ajoutée dans un réseau de neurone artificiel pour aider le réseau à apprendre des modèles complexes dans les données. Lorsque l'on compare avec un modèle basé sur les neurones qui se trouve dans notre cerveau, la fonction d'activation décide à la fin de ce qui doit être envoyé au prochain neurone. Il prend le signal de sortie de la cellule précédente et le convertit en une forme qui peut être prise comme entrée dans la cellule suivante. C'est une transformation non linéaire que nous effectuons pour les entrées que nous recevons avant de les envoyer à la couche ou au neurone suivant. Cette fonction est également connue sous le nom de fonction de transfert.




Figure 4 : Les types de fonctions de transfert utilisées dans les réseaux de neurone artificiels

3.5 Le biais :


Le biais est l'une des terminologies importantes de l'apprentissage automatique. Souvent, nous ajoutons un biais lors de la création de n'importe quel modèle dans un réseau de neurones artificiels.

On peut considérer que le biais de chaque neurone joue un rôle similaire à celui d'un seuil. En effet, la valeur du biais est ce qui va déterminer si la sortie d'activation d'un neurone va être propagée ou non dans le réseau.


En d'autres termes, le biais nous permet de savoir quand un neurone est activé de manière significative. L'ajout de ces biais finit par augmenter la flexibilité d'un modèle pour s'adapter aux données.

Dans un réseau de neurones, on nous donne l'entrée (x) et pour cette entrée, nous devons prédire la sortie (y). Ici, nous créons un modèle qui prédit la sortie.


Pendant l'apprentissage, le modèle lui-même trouve la valeur appropriée des constantes m et c . Supposons que nous avons le modèle $y = mx$ au lieu de $y = mx + c$.



ici modèle a la contrainte de s'entraîner et de trouver une ligne qui passe uniquement par l'origine.



La plupart du temps, il est impossible pour l'algorithme d'ajuster le modèle pour qu'il passe par l'origine à partir des données d'entrées.



Donnons une certaine liberté à l’algorithme en changeant le modèle comme $mx + c$ au lieu de mx , afin que le modèle puisse trouver une ligne qui correspond aux données.

Maintenant, il a la pleine liberté de s’entraîner et de trouver un modèle qui correspond le mieux aux données. Ici, la constante c est le biais.

Le biais est une constante qui aide le modèle à s’adapter au mieux aux données. En d’autres termes il est une constante qui donne la liberté de performer au mieux.

3.6 Propagation avant :

La propagation avant est la phase d’entraînement du modèle, où l’estimation des paramètres est calculée.

Le but principal de cette étape est le calcul de l’erreur global du réseau.

$$\text{propagation avant} \rightarrow a_k = g \left(\sum_j w_{j,k} a_j \right)$$

Pendant cette phase, on initialise les poids du réseau par des valeurs aléatoires. L’information ne se déplace que dans une seule direction, vers l’avant, à partir des nœuds d’entrée, en passant par les couches cachées et vers les nœuds de sortie.




Figure 5 : Les couches d'un réseau de neurone artificiel

3.7 La rétropropagation :

La rétropropagation, également connue sous le nom de backpropagation, est une méthode d'apprentissage automatique utilisée pour entraîner les réseaux de neurones artificiels. Elle est basée sur la minimisation de l'erreur entre les sorties attendues et les sorties réelles du réseau.

La rétropropagation fonctionne de la manière suivante :

- Entrée des données : les données d'entrée sont fournies au réseau de neurones artificiel.
- Propagation avant : les données d'entrée sont propagées à travers le réseau de neurones artificiel, calculant les sorties de chaque neurone.
- Calcul de l'erreur : l'erreur entre les sorties attendues et les sorties réelles est calculée.
- Rétropropagation : l'erreur est rétropropagée à travers le réseau de neurones artificiel, ajustant les poids et les seuils des neurones pour minimiser l'erreur.
- Mise à jour des poids : les poids et les seuils des neurones sont mis à jour en fonction de l'erreur et de la dérivée de la fonction coût.
- Répétition : les étapes 2 à 5 sont répétées jusqu'à ce que l'erreur soit minimale.

La rétropropagation est une méthode efficace pour entraîner les réseaux de neurones artificiels, car elle permet de minimiser l'erreur de manière efficace et de prendre en compte les interactions complexes entre les neurones.

← rétropropagation

$$\Delta[j] = g(in_j)(1 - g(in_j)) \sum_k w_{j,k} \Delta[k]$$

3.8 Fonction d'erreur :

Dans les réseaux de neurones, la fonction d'erreur (ou fonction de perte) est une mesure utilisée pour évaluer à quel point les prédictions du réseau neuronal correspondent aux valeurs attendues (les étiquettes ou labels) pour un ensemble de données donné.

Son rôle principal est de quantifier la différence entre la sortie réelle du réseau et la sortie désirée, ce qui permet au réseau de mettre à jour ses poids et ses biais lors de l'apprentissage afin de minimiser cette différence.

La fonction d'erreur varie en fonction du type de problème à résoudre.

- Pour les problèmes de régression (prédire une valeur numérique), une fonction d'erreur courante est l'erreur quadratique moyenne (MSE - Mean Squared Error).
- Pour les problèmes de classification (prédire une étiquette de classe), des fonctions d'erreur courantes incluent l'entropie croisée (cross-entropy) et l'erreur de classification.
- Pour d'autres tâches spécifiques, il existe des fonctions d'erreur adaptées, comme la divergence de Kullback-Leibler pour les modèles de génération de données.

La fonction d'erreur est un élément crucial dans l'entraînement des réseaux de neurones, car elle fournit au modèle un signal pour ajuster ses paramètres afin de minimiser l'écart entre ses prédictions et les véritables valeurs cibles.

$$C(w, b) = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

Où

- y_b est la sortie obtenue par la propagation avant.
- y est la sortie désirée.

Cette fonction d'erreur est notée généralement $C(\theta)$ où θ est le paramètre regroupant les poids et le biais

$$\theta = (w_{ij}, b_j).$$

3.9 Algorithme de descente du gradient :

L'algorithme de descente du gradient est une méthode d'optimisation utilisée pour minimiser les fonctions de coût ou les fonctions d'erreur, souvent rencontrées lors de l'entraînement de modèles de machine learning, y compris les réseaux de neurones.

Voici comment cela fonctionne :

- Initialisation des paramètres : Tout d'abord, les poids et les biais du modèle sont initialisés avec des valeurs aléatoires ou parfois avec des valeurs spécifiques. Ces paramètres sont ceux que l'algorithme va ajuster pour minimiser la fonction de coût.
- Calcul du gradient : Ensuite, pour chaque paramètre du modèle, le gradient de la fonction de coût par rapport à ce paramètre est calculé. Le gradient indique la direction dans laquelle la fonction de coût augmente le plus rapidement. Pour minimiser la fonction de coût, nous voulons aller dans la direction opposée, c'est pourquoi nous utilisons le négatif du gradient.
- Mise à jour des paramètres : Les paramètres du modèle sont mis à jour en fonction du gradient calculé et d'un taux d'apprentissage (learning rate), qui contrôle la taille des pas que nous faisons dans la direction du gradient. La mise à jour des paramètres se fait souvent selon la formule suivante :
 - paramètre = paramètre – taux d'apprentissage x gradient.
- Répétition : Les étapes 2 et 3 sont répétées jusqu'à ce qu'un critère d'arrêt soit atteint, tel qu'un nombre fixe d'itérations ou une convergence de la fonction de coût en dessous d'un certain seuil.

3.10 Les types des réseaux de neurones :

Perceptron monocouche :

C'est historiquement le premier réseau de neurones, proposé par Rosenblatt en 1958. C'est un réseau simple, puisqu'il ne se compose que d'une couche d'entrée et d'une couche de sortie. Il est calqué, à la base, sur le système visuel et de ce fait, il a été conçu dans un but premier à la reconnaissance de formes.





Figure 6: Carte conceptuelle des réseaux de neurones artificiels

Malgré la simplicité de cette architecture et de l'algorithme utilisé, le perceptron simple s'avère très utile pour des fonctions linéaires de classement. Mais les difficultés apparaissent si deux classes sont linéairement non séparables. Dans ce cas, il faut ajouter d'autres couches de neurones. Donc, le perceptron multicouche s'impose comme solution.

Perceptron multicouche :

Dans ce Perceptron multicouche, la première couche est affectée à des décisions très simples, en pondérant les données d'entrée. Les données de sortie sont ensuite traitées dans une deuxième couche, dont les décisions sont pondérées par les résultats de la première couche, et se situent donc à un niveau plus complexe et plus abstrait. Le processus de décision devient encore plus complexe avec une troisième couche, et ainsi de suite. En fin de compte, plus le nombre de couches d'un perceptron est élevé, plus sa capacité de prise de décision est grande.



21

Figure 7: Réseaux de neurones multicouches

❖ Couche d'entrée

La première couche est appelée la couche d'entrée. Elle va recevoir les données sources que nous voulons utiliser pour l'analyse. Par exemple dans le cas de la reconnaissance des chiffres manuscrits sous forme d'image, cette couche va recevoir les pixels de l'image. Sa taille est donc directement déterminée par le nombre de variables d'entrée.

❖ Couches cachées

La deuxième couche est une couche cachée, en ce sens qu'elle n'a qu'une utilité intrinsèque pour le réseau neuronal et n'a aucun contact direct avec l'extérieur. Les fonctions d'activation sont en général non linéaires sur cette couche mais il n'y a pas de règle à respecter. Le choix de nombre de couches cachées n'est pas implicite et doit être ajusté.

❖ Couche de sortie

La troisième couche est appelée couche de sortie. Elle donne le résultat obtenu après compilation par le réseau de données d'entrée de la première couche. Dans le cas de la reconnaissance des chiffres manuscrits, cette couche contient 10 neurones, chacun d'entre eux contenant un chiffre de 0 à 9. Sa taille est directement déterminée par le nombre de classes (ou modes de fonctionnement).

3.11 L'entraînement d'un réseau de neurones profonds :

L'entraînement d'un réseau de neurones consiste à faire en sorte que la machine trouve, seule:

- Les bonnes valeurs pour tous les biais (b) du réseau.
- Les bonnes valeurs pour tous les poids (w) du réseau Concrètement, nous allons donc, dans l'ordre.
- Fournir des données aléatoires pour tous les b et w du réseau.
- Fournir en entrée (dans la couche d'entrée) des données labellisées (i.e. des données dont on connaît la sortie attendue).
- Laisser la machine faire ses calculs (i.e. calculer les résultats des neurones (pré-activation et activation) jusqu'à la couche de sortie).
- Laisser la machine comparer les résultats obtenus avec les résultats attendus.
- Laisser la machine corriger plus ou moins fortement les b et w afin de minimiser l'erreur (l'écart entre ce qui a été prédit et ce que l'on espérait voir être prédit).
- Recommencer (i.e. fournir en entrée des données labellisées, laisser la machine faire ses calculs jusqu'à la couche de sortie, calculer l'erreur ... etc.)

4. Les réseaux de neurones convolutifs (CNN) :

4.1 Définition :

Dans les réseaux de neurones, les réseaux de neurones convolutifs (ConvNets ou CNNs) sont l'une des principales catégories pour faire de la reconnaissance d'images, des classifications d'images. La détection d'objets, la reconnaissance de visages, etc., sont quelques-uns des domaines où les CNN sont largement utilisés.




Figure 8 : Architecture du CNN

Les classifications d'images CNN prennent une image d'entrée, la traitent et la classent dans certaines catégories (par exemple, chien, chat, tigre, lion). Les ordinateurs voient une image d'entrée sous la forme d'un tableau de pixels et cela dépend de la résolution de l'image. En fonction de la résolution de l'image, il verra $h \times l \times d$ (h = Hauteur, w = Largeur, d = Dimension). Par exemple, une image de $6 \times 6 \times 3$ matrice de RVB (3 fait référence aux valeurs RVB) et une image de $4 \times 4 \times 1$ tableau de matrice d'image en niveaux de gris.

4.2 Couche de convolution :

La convolution est la première couche permettant d'extraire des entités d'une image en entrée. La convolution préserve la relation entre les pixels en apprenant les caractéristiques de l'image à l'aide de petits carrés de données d'entrée. Il s'agit d'une opération mathématique qui prend deux entrées telles qu'une matrice d'image et un filtre ou un noyau.

La matrice d'images multiplie la matrice du noyau ou du filtre :




Figure 9 : Illustration de la couche de convolution dans un CNN

Considérons un 5×5 dont les valeurs de pixel de l'image sont 0, 1 et la matrice de filtre 3×3 comme indiqué ci-dessous

La matrice d'images multiplie la matrice du noyau ou du filtre.

Ensuite, la convolution de la matrice d'images 5×5 se multiplie avec la matrice de filtres 3×3 qui est appelée « Feature Map » comme indiqué ci-dessous.

La convolution d'une image avec différents filtres peut effectuer des opérations telles que la détection des bords, le flou et la netteté en appliquant des filtres. L'exemple ci-dessous montre différentes images de convolution après l'application de différents types de filtres (noyaux).

La foulée est le nombre de pixels décalés sur la matrice d'entrée. Lorsque la foulée est de 1, nous déplaçons les filtres à 1 pixel à la fois. Lorsque la foulée est de 2, nous déplaçons les filtres à 2 pixels à la fois et ainsi de suite. La figure ci-dessous montre que la convolution fonctionnerait avec une foulée de 2.




Figure 10: Max pooling avec un filtre 3 x 3

4.3 Rembourrage :

Parfois, le filtre ne s'adapte pas parfaitement à l'image d'entrée. Deux options s'offrent à nous:

- Rembourrez l'image avec des zéros (remplissage du zéro) pour qu'elle s'adapte.
- Déposez la partie de l'image où le filtre ne s'adaptait pas. C'est ce qu'on appelle un remplissage valide, qui ne conserve qu'une partie valide de l'image.

4.4 Non-linéarité (ReLU) :

ReLU est l'abréviation de Rectified Linear Unit pour un fonctionnement non linéaire. La sortie est $f(x) = \max(0, x)$.

Pourquoi ReLU est important : Le but de ReLU est d'introduire la non-linéarité dans notre ConvNet. Étant donné que les données du monde réel voudraient que notre ConvNet apprenne des valeurs linéaires non négatives.




Figure 11: Illustration de la couche ReLU

Il existe d'autres fonctions non linéaires telles que tanh ou sigmoïde qui peuvent également être utilisées à la place de ReLU. La plupart des data scientists utilisent ReLU car en termes de performances, ReLU est meilleur que les deux autres.

4.5 Couche de mise en commun :

La mise en commun des calques réduirait le nombre de paramètres lorsque les images sont trop grandes. La mise en commun spatiale, également appelée sous-échantillonnage ou sous échantillonnage, réduit la dimensionnalité de chaque carte tout en conservant des informations importantes. La mise en commun spatiale peut être de différents types :

- Mise en commun maximale
- Mutualisation moyenne
- Mise en commun de la somme

La mise en commun maximale prend l'élément le plus volumineux de la carte d'entités rectifiée. Prendre l'élément le plus grand pourrait également prendre la mise en commun moyenne. Somme de tous les éléments de l'appel de la carte d'entités en tant que regroupement de somme.

4.6 Couche entièrement connectée :

La couche que nous appelons couche FC, nous avons aplati notre matrice en vecteur et l'avons introduite dans une couche entièrement connectée comme un réseau neuronal[6].

Conclusion:

Ce chapitre explore les fondements de l'intelligence artificielle, en mettant l'accent sur l'apprentissage automatique (machine learning), l'apprentissage profond (deep learning), et les réseaux de neurones. L'apprentissage automatique comprend des techniques telles que l'apprentissage non supervisé et supervisé, utilisées pour la classification et la régression dans une variété de domaines d'application. L'apprentissage profond, une sous-catégorie de l'apprentissage automatique, est particulièrement efficace dans des domaines

tels que la reconnaissance d'images et de la parole. Les réseaux de neurones, la pierre angulaire de nombreuses applications d'IA, sont examinés en détail, y compris leurs différentes couches et fonctions. Enfin, les réseaux de neurones convolutifs (CNN) sont présentés pour leur efficacité dans la détection et la classification d'objets dans des images en temps réel.

Chapitre II : Présentation des images satellitaires et drones

Introduction :

L'imagerie aérienne est devenue un outil essentiel dans plusieurs domaines tels que la cartographie, l'agriculture de précision, la surveillance environnementale, ou encore la gestion des catastrophes naturelles. Grâce aux avancées technologiques, deux principales sources d'acquisition d'images sont couramment utilisées : les images satellites et les images obtenues par drones. Ce chapitre vise à présenter ces deux types d'imagerie, expliquer leur fonctionnement, leur composition, et établir une comparaison entre eux afin de comprendre leur complémentarité et les raisons de leur choix dans le cadre de ce projet.

1. Les images satellites :

1.1 Définition :

Les images satellites sont des représentations visuelles de la Terre acquises depuis l'espace par des satellites équipés de capteurs spécialisés. Elles permettent de capturer, à intervalles réguliers, de vastes surfaces terrestres en différentes longueurs d'onde, visibles ou invisibles à l'œil humain, et sont largement utilisées pour le suivi environnemental à l'échelle globale. [7]



Figure12 :illustration de satellite et imagerie satellitaire

1.1 Types de satellites (Sentinel, Landsat, SPOT...) :

Il existe plusieurs familles de satellites dédiés à l'observation de la Terre, chacune répondant à des objectifs scientifiques, environnementaux ou stratégiques :

- **Landsat** (NASA/USGS) : programme historique lancé dans les années 1970. Il fournit des images multispectrales avec une résolution de 30 mètres, idéales pour le suivi de l'environnement à long terme.
- **Sentinel** (programme Copernicus de l'Union européenne) : les Sentinel-1 (radar) et Sentinel-2 (optique multispectral) revisitent chaque zone tous les 5 jours avec une couverture systématique, ce qui en fait un outil essentiel pour la surveillance environnementale.
- **SPOT** (France, CNES) : offre des images à haute résolution (jusqu'à 1,5 mètre) pour des applications de cartographie, d'agriculture ou de gestion du territoire.

Chaque satellite est conçu selon des besoins opérationnels spécifiques, intégrant des capteurs variés selon les objectifs : agriculture, climat, catastrophes naturelles ou planification urbaine.

1.2 Types d'images (optique, radar, multispectrale) :

Selon les capteurs embarqués, les satellites acquièrent différents types d'images :

- **Images optiques** : capturent la lumière visible. Elles sont comparables à la vision humaine et sont largement utilisées pour l'analyse du paysage.
- **Images multispectrales / hyperspectrales** : enregistrent des informations dans plusieurs bandes spectrales (visible, infrarouge, proche infrarouge...). Ces images permettent d'analyser la santé de la végétation, la teneur en eau du sol ou les matériaux en surface.
- **Images radar (SAR)** : utilisent des ondes électromagnétiques pour capter la surface terrestre, de jour comme de nuit, et à travers les nuages. Très utiles en conditions météorologiques défavorables.

1.3 Caractéristiques techniques :

- **Résolution spatiale** : désigne la taille minimale d'un objet détectable dans une image. Par exemple, Sentinel-2 offre 10 m, Landsat 30 m, et WorldView peut descendre à 30 cm.

- **Résolution temporelle** : indique la fréquence de passage du satellite sur une même zone. Sentinel-2 revisite une zone tous les 5 jours, favorisant le suivi fréquent.
- **Résolution spectrale** : décrit le nombre et la largeur des bandes spectrales détectées. Une image RGB standard a 3 bandes (rouge, vert, bleu), alors qu'une image multispectrale peut en contenir de 5 à 13, et une image hyperspectrale plus de 100.

1.4 Domaines d'utilisation (agriculture, environnement, cartographie...) :

Les images satellites sont utilisées dans des secteurs variés :

- suivi de croissance, détection de stress hydrique, estimation de rendement
- Environnement : observation des forêts, des zones humides, de la pollution
- Cartographie : élaboration de cartes topographiques, d'occupation du sol
- Gestion des risques : détection d'incendies, inondations, glissements de terrain

2. Les images drones :

Les drones, ou aéronefs télépilotés, sont des systèmes capables de voler sans pilote à bord, généralement à basse altitude, et de capturer des images en très haute résolution. Leur déploiement rapide, leur précision centimétrique et leur adaptabilité les rendent essentiels dans les missions localisées nécessitant une observation détaillée.

2.1 Définition :

Les images drones sont des données visuelles acquises par des aéronefs sans pilote volant à basse altitude. Elles permettent de capturer des images très haute résolution, idéales pour des missions localisées nécessitant une grande précision.



Figure13 :Drone et exemple d' Image

2.2 Types de drones (multirotors, aile fixe...) :

On distingue deux grandes familles :

- ❖ **Drones multirotors** : équipés de plusieurs hélices (généralement 4 à 8), ces drones sont faciles à manœuvrer, capables de vol stationnaire, et sont utilisés pour des missions précises sur des zones restreintes, comme les inspections techniques.
- ❖ **Drones à aile fixe** : similaires à de petits avions, ils sont plus adaptés aux longues distances et aux grands territoires (zones agricoles, forêts), avec une autonomie de vol plus importante.

2.3 Capteurs embarqués (RGB, multispectral, thermique...) :

Les drones peuvent embarquer plusieurs types de capteurs :

- **Caméras RGB** : capturent des images en couleur standard, utilisées pour la cartographie visuelle.
- **Capteurs multispectraux** : mesurent des bandes spectrales supplémentaires pour évaluer l'état de la végétation, les sols ou les matériaux (NDVI, NDRE...).
- **Capteurs thermiques** : détectent les variations de température, utiles pour l'inspection de réseaux, de bâtiments ou la détection de stress hydrique.

2.4 Avantages du drone :

Le drone présente plusieurs avantages :

- **Résolution spatiale très élevée** : capable de détecter des objets de quelques centimètres.

- **Flexibilité** : vols à la demande, trajectoires personnalisables.
- **Coût maîtrisé** : surtout pour des interventions ponctuelles ou sur de petites zones.
- **Autonomie et rapidité d'intervention** : idéal pour des missions urgentes ou des environnements difficiles d'accès.

2.5 Domaines d'application (inspection, modélisation 3D, suivi de projet...) :

Les drones sont utilisés pour :

- **Inspection technique** : lignes électriques, barrages, bâtiments, panneaux solaires.
- **Modélisation 3D et photogrammétrie** : reconstitution numérique de sites.
- **Suivi de projet ou de chantier** : comparaison temporelle de l'évolution.
- **Agriculture de précision** : surveillance des cultures, identification de zones à traiter.
- **Gestion forestière et environnementale** : estimation du couvert végétal, surveillance de la biodiversité.

3.Comparaison entre les images satellites et les images drones :

3.1 Résolution (spatiale, temporelle) :

Drones : offrent une résolution spatiale très fine (quelques centimètres), adaptée à la détection précise d'objets. Cependant, ils ne disposent pas de capacité de revisite automatique.

Satellites : bien que leur résolution spatiale soit souvent inférieure (de quelques mètres à quelques dizaines de centimètres), leur fréquence de passage (résolution temporelle) permet un suivi régulier des zones observées.

3.2 Couverture et accessibilité :

Satellites : couvrent de larges superficies (jusqu'à plusieurs centaines de km²) et les données sont souvent disponibles gratuitement (ex. Sentinel).

Drones : limités à de petites zones, mais extrêmement précis et adaptables. Leur déploiement nécessite un accès physique à la zone.

3.3 Coût et logistique :

Satellites : économiques pour les projets régionaux ou globaux, mais nécessitent des traitements complexes des données.

Drones : investissement initial modéré, mais impliquent des autorisations de vol, un personnel qualifié et une logistique terrain.

3.4 Adaptation selon le type de projet :

Satellites : adaptés aux études environnementales à large échelle, à la planification territoriale ou à la surveillance climatique.

Drones : plus appropriés pour les projets localisés, les inspections techniques, ou les applications agricoles de précision.

3.5 Avantages et inconvénients de chaque source :

Satellites :

- ❖ **Avantages** : couverture étendue, fréquence régulière, données gratuites pour certains programmes.
- ❖ **Inconvénients** : dépendance aux conditions météorologiques (optique), résolution parfois insuffisante pour les petits objets.

Drones :

- ❖ **Avantages** : très haute résolution, flexibilité, données personnalisées.
- ❖ **Inconvénients** : portée limitée, contraintes réglementaires, coût humain sur le terrain.

Conclusion :

Les images satellites et les images drones ne s'opposent pas, mais se complètent dans une logique de synergie technologique. Tandis que les satellites offrent une

vision globale et continue du territoire, les drones apportent une finesse d'analyse inégalée sur des zones ciblées. Le choix de l'un ou l'autre dépend des objectifs, des contraintes opérationnelles et des échelles d'étude. Intégrer ces deux sources dans une approche combinée permet d'optimiser la précision, la rapidité et l'efficacité des projets de télédétection, tant dans la recherche scientifique que dans les applications opérationnelles (CNES, Copernicus, UN-SPIDER, IGN, 2023).

Chapitre III. Modèles de détection et de segmentation d'objets

Introduction :

L'analyse automatique d'images géospatiales, qu'elles proviennent de satellites ou de drones, repose sur des techniques avancées de vision par ordinateur. Deux tâches fondamentales s'imposent dans ce domaine : la détection d'objets et la segmentation d'images. Ces approches, bien que complémentaires, répondent à des objectifs différents : localiser, identifier ou encore délimiter avec précision les objets d'intérêt présents dans une image. L'essor des modèles d'intelligence artificielle, notamment ceux basés sur les réseaux de neurones profonds, a permis des avancées notables dans l'automatisation de ces tâches, avec des performances inégalées dans les domaines de l'urbanisme, de l'agriculture, de l'environnement ou encore de la gestion des risques naturels.

1. Tâches fondamentales d'analyse d'image : détection et segmentation :

1.1 Détection d'objets :

1.1.2 Définition de la détection :

La détection d'objets consiste à localiser et classier automatiquement les objets présents dans une image à l'aide de boîtes englobantes (bounding boxes). Chaque détection est associée à une classe (ex. : véhicule, bâtiment) et à une probabilité de confiance.

1.1.3 Fonctionnement général (bounding boxes, confidence, classes) :

Les modèles de détection produisent pour chaque image un ensemble de prédictions sous forme :

- Boîtes de délimitation (bounding boxes),
- Scores de confiance (confidence scores),
- Étiquettes de classe (labels).

→ Le modèle apprend à détecter ces éléments à partir d'un entraînement supervisé sur un jeu de données annoté.

1.1.4 Exemples d'application dans l'imagerie aérienne :

Dans l'imagerie aérienne, la détection permet d'identifier automatiquement les bâtiments, les véhicules, les routes, ou encore les plantations agricoles. Cela facilite l'inventaire urbain, le suivi de trafic ou la surveillance environnementale.

1.1.5 Importance dans l'extraction automatique d'objets :

La détection est cruciale pour des systèmes de cartographie automatisée ou pour initier des processus d'analyse plus poussés (comme la segmentation), car elle fournit une localisation initiale des objets d'intérêt.

1.2.Segmentation d'images :

1.2.1 Définition :

La segmentation est une technique qui consiste à attribuer à chaque pixel d'une image une étiquette correspondant à une classe spécifique, permettant ainsi une délimitation fine des objets.

1.2.2 Objectifs dans le traitement d'images géospatiales :

En télédétection, la segmentation permet de distinguer les différents types de surfaces (eau, forêt, zone urbaine, cultures) avec une précision géographique élevée. Elle est essentielle dans la classification d'occupation du sol.

1.2.3 Rôle dans l'analyse détaillée de l'image :

La segmentation fournit une compréhension approfondie de la structure spatiale d'une image. Elle est utilisée pour la détection de changements, l'analyse de dommages ou la cartographie thématique.

1.2.4 Types de segmentation :

1.2.4.1 Segmentation sémantique :

1.Définition :

La segmentation sémantique assigne un label de classe à chaque pixel, sans distinction entre les objets individuels appartenant à une même classe.

2.Exemple (classification pixel par pixel sans distinction d'objets) :

Tous les pixels représentant une route auront le même label, qu'ils appartiennent à une ou plusieurs routes distinctes.

1.2.4.2 Segmentation d'instance :

1.Définition :

La segmentation d'instance combine détection et segmentation en identifiant chaque objet individuellement, même s'ils appartiennent à la même classe.

2.Exemple (chaque objet séparé même s'il est de la même classe) :

Chaque voiture dans un parking sera détectée et segmentée séparément, avec sa propre instance.

1.2.4.3 Différences entre les deux types :

1.Tableau comparatif :

Critère	Segmentation sémantique	Segmentation d'instance
Niveau de précision	Classe par pixel	Objet individuel par classe
Utilité	Cartographie, occupation du sol	Comptage, suivi, analyse urbaine
Complexité du modèle	Moyenne	Élevée (combine détection + segment)




Figure 14 :différence entre sémantique et instance

2.Choix selon les objectifs du projet :

Le choix dépend des besoins : pour des cartes générales, on privilégiera la segmentation sémantique ; pour des projets nécessitant une analyse individuelle des objets, on optera pour la segmentation d'instance.

1.3 Différence entre détection et segmentation :

La détection localise les objets par des rectangles (bounding boxes) sans les délimiter précisément, tandis que la segmentation fournit une carte fine pixel par pixel. Ces deux tâches peuvent être complémentaires : la détection sert souvent de première étape à une segmentation plus précise, notamment dans les modèles modernes comme Mask R-CNN.




Figure 15 :illustration de différence entre segmentation et détection

2.Modèles de détection et segmentation :

2.1 YOLO :

2.1.1 Définition :

YOLO (You Only Look Once), est un algorithme populaire de détection d'objets en temps réel. YOLO combine ce qui était autrefois un processus en plusieurs étapes, en utilisant un seul réseau neuronal pour effectuer à la fois la classification et la prédiction des boîtes englobantes pour les objets détectés. En tant que tel, il est fortement optimisé pour les performances de détection et peut s'exécuter beaucoup plus rapidement que l'exécution de deux réseaux neuronaux distincts pour détecter et classer les objets séparément. Pour ce faire, il réutilise les classificateurs d'images traditionnels pour les utiliser pour la tâche de régression consistant à identifier les boîtes englobantes pour les objets. Cet article ne s'intéressera qu'à YOLOv1, la première des nombreuses itérations que cette architecture a connues. Bien que les itérations suivantes présentent de nombreuses améliorations, l'idée de base derrière l'architecture reste la même. YOLOv1, appelé simplement YOLO, peut fonctionner plus rapidement que la détection d'objets en temps réel à 45 images par seconde, ce qui en fait un excellent choix pour les applications qui nécessitent une détection en temps réel. Il regarde l'ensemble de l'image en une seule fois, et une seule fois - d'où le nom You Only Look Once - ce qui lui permet de capturer le contexte des objets détectés. Cela réduit de moitié le nombre de détections de faux positifs par rapport aux R-CNN qui examinent séparément différentes parties de l'image. De plus, YOLO peut généraliser les représentations de divers objets, ce qui le rend plus applicable à une variété de nouveaux environnements. [3]

2.1.2 Version de YoLo :

- **YOLOv1 : La genèse d'une révolution**

YOLOv1 a posé les bases de l'architecture YOLO, introduisant un réseau neuronal convolutif unique qui prédit simultanément les classes d'objets et leurs boîtes englobantes. Cette approche unifiée, en contraste avec les détecteurs d'objets en deux étapes de l'époque, a permis une détection d'objets en temps réel à des vitesses sans précédent.

- **YOLOv2 : Vers une précision et une vitesse accrue**

YOLOv2 a marqué un progrès significatif en matière de précision et de vitesse. L'introduction de techniques telles que Batch Normalization, High-Resolution CNNs et Convolutional with Anchor Boxes a permis une meilleure détection des petits objets et une meilleure gestion des variations d'échelle. YOLOv2 s'est imposé comme un choix incontournable pour les applications en temps réel exigeantes.

- **YOLOv3 : Franchir un nouveau cap en matière de performance**

YOLOv3 a porté la détection d'objets à un tout autre niveau. S'appuyant sur les succès de YOLOv2, YOLOv3 a introduit des fonctionnalités innovantes telles que Multi-Scale Prediction, Feature Pyramid Network (FPN) et Darknet-53 Network. Ces améliorations ont permis à YOLOv3 de surpasser les modèles concurrents en termes de précision et de vitesse, le consacrant comme l'un des détecteurs d'objets les plus performants de l'époque.

- **YOLOv4 : Intégrer les avancées de la communauté**

YOLOv4 a poursuivi la quête d'excellence en intégrant des éléments clés de la recherche en vision par ordinateur. L'adoption de Bag of Freebies, un ensemble de techniques éprouvées pour booster les performances, et l'introduction de CSPDarknet53, une architecture de réseau neuronal plus efficace, ont permis à YOLOv4 de s'imposer comme un choix de pointe pour les applications de détection d'objets complexes.

- **YOLOv5 : Une refonte axée sur la modularité et la flexibilité**

YOLOv5 a représenté une refonte majeure de l'architecture YOLO, en adoptant un paradigme axé sur les modules. L'introduction de concepts tels que CutMix, Data Augmentation et Adaptive Anchors a permis d'améliorer la robustesse, la généralisabilité et la flexibilité du modèle. YOLOv5 est rapidement devenu l'une des versions YOLO les plus populaires et les plus utilisées à ce jour.

- **YOLOv6 et version ultérieures :**

L'innovation dans la famille YOLO ne s'est pas arrêtée à YOLOv5. Des chercheurs et développeurs passionnés ont continué à repousser les limites de la performance en matière de détection d'objets, en donnant naissance à des versions ultérieures encore plus sophistiquées. Plongeons dans les détails de ces versions et découvrons les nouveautés qu'elles apportent.

- **YOLOv6 :**

Introduction de CSPNet : YOLOv6 a introduit CSPNet (CSP Darknet53), une architecture de réseau neuronal plus efficace et robuste, permettant une meilleure gestion des gradients et une meilleure propagation des informations à travers le réseau.

Focus sur les petits objets : YOLOv6 a porté une attention particulière à la détection des petits objets, en introduisant des techniques telles que SiouLoss et CoordConv. Ces améliorations ont permis une détection plus précise des objets de petite taille, un défi souvent rencontré dans les modèles de détection d'objets.

Meilleure intégration de YOLO Nano : YOLOv6 a facilité l'intégration de YOLO Nano, une version légère et optimisée pour les appareils mobiles, en la rendant plus accessible aux développeurs souhaitant déployer des modèles YOLO sur des plateformes à ressources limitées.

- **YOLOv7 :**

EffNetV2 : YOLOv7 a adopté EffNetV2 comme architecture de base, profitant de ses performances et de son efficacité en termes de calcul. Cela a permis à YOLOv7 d'atteindre une vitesse et une précision encore plus élevées.

Focus sur la détection des instances : YOLOv7 a introduit des améliorations dédiées à la détection des instances, notamment SiO-U-NMS et Double-Stuff IOU. Ces techniques ont permis une meilleure localisation et une meilleure séparation des objets qui se chevauchent.

Mise à jour de la boîte à outils YOLO : YOLOv7 a apporté des mises à jour à la boîte à outils YOLO, en améliorant la convivialité et en facilitant la personnalisation et l'adaptation du modèle aux besoins spécifiques des utilisateurs.

- **YOLOv8 :**

Scaled Dilated Attention Module (SAM) : YOLOv8 a introduit SAM, un module d'attention dilaté à échelle, qui permet une meilleure capture des dépendances contextuelles à différentes échelles. Cela a permis d'améliorer la précision de la détection, en particulier pour les objets complexes ou difficiles à distinguer.

Path Aggregation Network (PANet) : YOLOv8 a également introduit PANet, un réseau d'agrégation de chemins, qui facilite la fusion d'informations provenant de différentes échelles spatiales. Cela a permis d'améliorer la robustesse du modèle face aux variations d'échelle et de perspective.

Optimisations pour les performances en temps réel : YOLOv8 a inclus des optimisations spécifiques pour améliorer les performances en temps réel, le rendant idéal pour les applications où la vitesse est primordiale.

2.1.3 Architecture de yolov8 : [8]

- **Backbone** :
Il s'agit du réseau de neurones convolutif (**CNN**) chargé d'extraire les caractéristiques à partir de l'image d'entrée. YOLOv8 utilise un **backbone CSPDarknet53 personnalisé**, qui intègre des connexions partielles entre


les étapes (**Cross-Stage Partial Connections**) afin d'améliorer le flux d'informations entre les couches et d'augmenter la précision globale du modèle.

- **Neck** :

Le **neck**, ou "extracteur de caractéristiques intermédiaires", fusionne les cartes de caractéristiques provenant de différentes étapes du backbone pour capturer des informations à plusieurs échelles. L'architecture de YOLOv8 utilise un **nouveau module C2f** à la place du traditionnel **FPN (Feature Pyramid Network)**. Ce module combine les caractéristiques sémantiques de haut niveau avec les informations spatiales de bas niveau, ce qui améliore la précision de détection, notamment pour les petits objets.

- **Head** :

Le **head** est responsable de la prédiction finale. YOLOv8 utilise plusieurs modules de détection qui prédisent les **boîtes englobantes (bounding boxes)**, les **scores de présence d'objet (objectness scores)** et les **probabilités de classes** pour chaque cellule de la grille dans la carte de caractéristiques. Ces prédictions sont ensuite agrégées pour obtenir les détections finales.



2.2 U-Net :

2.2.1 Définition :


U-Net est un réseau de neurones convolutifs (CNN) conçu initialement pour la segmentation d'images médicales. Introduit par Olaf Ronneberger et al. en 2015, il s'est rapidement imposé comme un modèle incontournable pour la segmentation sémantique, notamment grâce à sa capacité à produire des masques pixel par pixel très précis, tout en fonctionnant efficacement avec peu de données annotées. En télédétection, U-Net est largement utilisé pour l'extraction de surfaces homogènes comme les zones bâties, les cultures, les forêts ou les routes. [1]

2.2.2 Architecture en U : encoder / decoder + skip connections :

U-Net est structuré en forme de "U", avec deux branches principales : [9]

- **L'encodeur (contracting path)** : composé de plusieurs couches convolutives et de pooling, il permet d'extraire les caractéristiques visuelles de plus en plus abstraites en réduisant progressivement la résolution spatiale.
- **Le décodeur (expansive path)** : composé de couches de convolution transposée (ou upsampling), il reconstruit l'image segmentée à partir des caractéristiques extraites.
- **Les skip connections** : ces connexions latérales relient chaque couche du décodeur à sa couche correspondante dans l'encodeur, permettant de conserver les détails spatiaux fins perdus lors du downsampling.

Ce mécanisme est crucial pour segmenter avec précision des objets fins et complexes, comme des routes, des contours de bâtiments ou des limites de champs agricoles.



2.2.3 Avantages pour les images haute résolution :

L'un des grands avantages de U-Net est sa capacité à gérer des images de grande taille avec une grande précision, même en présence de faibles volumes de données annotées. Il est donc particulièrement adapté aux images satellites et

drones, souvent très détaillées, et il peut être entraîné pour produire des résultats robustes en peu de temps.

Version ou modification utilisée (si applicable) :

Plusieurs variantes de U-Net ont été développées pour améliorer ses performances :

- **U-Net++** : intègre des connexions denses et redéfinit les chemins de décodage pour une segmentation plus fine.
- **Attention U-Net** : ajoute des mécanismes d'attention pour se concentrer sur les régions pertinentes de l'image.
- **ResUNet / DeepLabV3+** : combinent la structure de U-Net avec des backbones plus puissants comme ResNet ou MobileNet pour une segmentation plus efficace à grande échelle.

Dans les applications de télédétection, ces variantes sont utilisées pour segmenter précisément les éléments du paysage, même dans des contextes complexes comme les zones périurbaines, les cultures mixtes ou les zones humides.

2.3.Mask R-CNN :

2.3.1 Définition :


Mask R-CNN est un modèle d'apprentissage profond développé par Facebook AI Research (He et al., 2017). Il s'agit d'une extension du modèle Faster R-CNN, qui ajoute une branche de segmentation d'instance à la structure classique de détection. Mask R-CNN est capable de détecter chaque objet individuellement dans une image et de produire un masque binaire pour chacun, ce qui en fait un outil puissant pour l'analyse fine d'images aériennes où plusieurs objets se chevauchent. [2]

2.3.2 Architecture globale :

L'architecture de Mask R-CNN repose sur trois composants principaux :[10]

- **Backbone** : un réseau de neurones convolutifs profond (souvent ResNet + Feature Pyramid Network - FPN) utilisé pour extraire les caractéristiques de l'image.
- **Region Proposal Network (RPN)** : propose des régions d'intérêt (RoI) susceptibles de contenir des objets.
-
- **Heads de prédiction** :
 - Une tête pour la **classification des objets** (ex. : bâtiment, voiture),
 - Une tête pour les **coordonnées des boîtes englobantes** (bounding boxes),
 - Une troisième tête pour la **prédiction du masque binaire** correspondant à chaque instance.

Grâce au module **RoIAlign**, Mask R-CNN améliore la précision spatiale des masques, en alignant parfaitement les régions d'intérêt avec les prédictions de masque.



2.3.3 Versions utilisées et améliorations:

Depuis sa version originale, plusieurs améliorations de Mask R-CNN ont été proposées :

- **Hybrid Task Cascade (HTC)** : améliore les prédictions en affinant progressivement les masques et boîtes.
- **DetectoRS et PointRend** : ajoutent des modules de raffinement des bords pour mieux gérer les objets aux contours complexes.
- **Mask2Former (2021)** : version de nouvelle génération intégrant Transformers pour unifier segmentation sémantique, d'instance et panoptique.

Mask R-CNN reste un modèle référent pour la segmentation d'objets individuels dans des scènes complexes, et il est souvent utilisé dans les projets de cartographie urbaine, d'analyse post-catastrophe, de suivi de parc automobile ou d'estimation de densité de végétation.

Conclusion :

La détection et la segmentation sont deux piliers fondamentaux de l'analyse d'images géospatiales. Grâce aux avancées de l'apprentissage profond, des modèles puissants comme YOLO, U-Net ou Mask R-CNN permettent aujourd'hui d'automatiser avec une grande précision l'extraction d'informations à partir d'images issues de drones ou de satellites. Le choix entre détection, segmentation sémantique ou d'instance dépend des objectifs du projet, de l'échelle d'analyse, et des exigences en matière de précision. Ces outils ouvrent la voie à une nouvelle génération de systèmes intelligents d'aide à la décision dans des domaines aussi variés que la gestion urbaine, l'agriculture de précision ou la surveillance environnementale.

CHAPITRE IV. Classification et Segmentation des images satellitaires et Drones

Introduction:

L'avènement des techniques de vision par ordinateur appliquées à la télédétection a permis de développer des méthodes automatisées pour l'analyse des images issues de satellites et de drones. Dans ce projet, nous avons conçu et expérimenté un pipeline complet de détection et de segmentation d'objets géospatiaux, en exploitant des données réelles provenant de différentes sources (satellite et drone). L'objectif principal est de comparer l'efficacité de plusieurs modèles d'apprentissage profond, notamment YOLOv8, U-Net et Mask R-CNN, dans la reconnaissance et la délimitation précise de classes telles que les bâtiments, les routes, la végétation ou d'autres infrastructures. Le workflow mis en place repose sur une méthodologie rigoureuse en cinq grandes étapes : l'acquisition des images, l'annotation des données, le prétraitement, l'entraînement des modèles, et enfin l'évaluation des performances. Ce travail vise à démontrer le potentiel de l'intelligence artificielle dans l'interprétation automatique de données géospatiales à grande échelle.

Préparation des données (collecte, annotation, prétraitement) :

Les images utilisées dans ce projet proviennent de Kaggle (pour les images satellites) et de Roboflow (pour les images drones). Les jeux de données ont été sélectionnés pour leur diversité et leur qualité d'annotation initiale. Des ajustements manuels ont été réalisés via LabelImg et Roboflow Annotate pour uniformiser les classes et corriger certaines erreurs.

Les images ont ensuite été prétraitées par redimensionnement, normalisation et augmentation (flip, rotation, recadrage), afin d'optimiser leur compatibilité avec les modèles d'apprentissage profond.

Choix et configuration des modèles de deep learning :

Trois modèles ont été retenus pour leur complémentarité : YOLOv8 pour la détection rapide, U-Net pour la segmentation sémantique pixel par pixel, et Mask R-CNN, également utilisé ici pour de la segmentation sémantique, malgré

son architecture initialement conçue pour la segmentation d'instance. Chaque modèle a été configuré selon le format des données (COCO, YOLO), le nombre de classes, et les dimensions des images, avec ajustement des hyperparamètres (learning rate, batch size, epochs).

Entraînement/validation croisée :

Les données ont été divisées en trois ensembles : 70 % pour l'entraînement, 20 % pour la validation et 10 % pour les tests. Une validation croisée a été appliquée pour garantir la robustesse des résultats. L'optimisation des modèles a été réalisée avec l'algorithme **Adam**, et les hyperparamètres ont été ajustés manuellement en fonction des performances obtenues sur le jeu de validation

Évaluation des performances :

Les performances ont été mesurées à l'aide de deux métriques principales : **IoU** (Intersection over Union) et le **coefficient de Dice**. Ces indicateurs ont permis d'évaluer la qualité des segmentations en comparant les masques prédits aux annotations réelles, selon le type de modèle et la nature des images (satellites ou drones). IoU mesure le recouvrement entre les zones prédites et les zones réelles, tandis que le Dice score est particulièrement adapté aux classes déséquilibrées, en évaluant la similarité entre les régions segmentées.

Analyse comparative et perspectives d'amélioration :

L'analyse comparative des résultats montre que les performances des modèles varient selon la source des images et la complexité des scènes. **U-Net** s'est montré très efficace sur les images satellites avec des surfaces homogènes, tandis que **YOLOv8** a donné de bons résultats sur les images drones, notamment pour la détection rapide d'objets bien définis. **Mask R-CNN**, utilisé ici pour la segmentation sémantique, a produit des masques de bonne qualité mais avec un temps d'inférence plus élevé.

Pour améliorer les performances futures, plusieurs pistes peuvent être envisagées :

- Intégrer des modèles plus récents comme SAM (Segment Anything Model) ou Mask2Former pour une meilleure précision de segmentation.
- Renforcer l'ensemble de données avec des annotations plus variées et équilibrées, en particulier pour les classes minoritaires.
- Appliquer des stratégies de post-traitement (filtrage morphologique, fusion de masques) pour corriger les erreurs en bordure d'objet.

1.Zone d'étude et Données utilisées :

1.1 Présentation de la zone géographique analysée :

La zone d'étude se situe dans une région urbaine et périurbaine, caractérisée par une diversité spatiale intéressante : zones bétonnées, routes, végétation, et structures bâties. Cette hétérogénéité permet de tester différents types de segmentation et de détection d'objets géospatiaux à partir d'images satellites et drones..

Dans ce projet, les images utilisées proviennent de jeux de données adaptés à des modèles spécifiques. Voici quelques exemples illustratifs de ces images et leur usage dans le pipeline :

- Vue aérienne capturée par drone d'un parking urbain, contenant des bordures, marquages au sol et éléments de mobilier urbain. Ce type d'image est utilisé pour la segmentation sémantique de zones précises via Mask R-CNN.




Figure 16 : Image utilisée pour Mask R-CNN

- Image satellite haute résolution représentant une zone semi-rurale structurée en parcelles agricoles, routes et zones construites. Elle sert à la segmentation sémantique à large échelle avec le modèle U-Net, pour la classification des types d'occupation du sol.



Figure 17 : Image utilisée pour U-Net

- À gauche : Prise de vue drone d'une route en milieu urbain montrant plusieurs véhicules et deux-roues. Cette image, extraite d'un dataset Roboflow, est utilisée pour l'entraînement de YOLOv8 dans le cadre de la détection rapide d'objets mobiles (voitures, motos, camions).
- À droite : Image satellite représentant un aéroport international, issue d'un dataset public. Elle est exploitée pour la segmentation sémantique des infrastructures (terminaux, pistes, avions) avec U-Net.



Figure 18 : Images utilisées pour YOLOv8

1.2 Sources des données (images satellite & drone) :

Deux jeux de données principaux ont été exploités dans ce projet :

- **Images satellites** : extraites de jeux de données publics disponibles sur Kaggle, contenant des images multi-résolution issues de satellites comme Sentinel-2 ou similaires.
- **Images drones** : récupérées à partir de la plateforme Roboflow, fournies dans le cadre de projets open source, généralement capturées par drones multicopters équipés de caméras RGB haute résolution.

1.3 Annotation et préparation des données pour l'entraînement :

Les images utilisées dans ce projet proviennent de jeux de données déjà annotés, téléchargés depuis Kaggle (images satellites) et Roboflow (images drones). Les

annotations étaient disponibles aux formats YOLO ou COCO, selon les jeux de données.

Une vérification manuelle a été effectuée afin de contrôler la qualité des annotations et d'adapter les classes aux besoins du projet. Dans certains cas, les annotations ont été modifiées ou restructurées pour assurer la cohérence avec les modèles utilisés (ex. : regroupement ou renommage des classes). Enfin, les images ont été prétraitées et organisées pour les phases d'entraînement, validation et test.

1.3 Paramètres des données d'entraînement par modèle :

Nom du Dataset	Drone : dronedataset-n1dlr Satellite : Arirang	Drone : Kahana Bay Satellite : DeepGlobe Land Cover	Drone : Kahana Bay
Type de tâche	<i>Détection d'objets</i>	Segmentation sémantique	Segmentation sémantique
Source	Drone :Roboflow universe Satellite :Kaggle	Satellite : Kaggle	Drone :Roboflow universe
Référence	Drone : https://universe.roboflow.com/iamnova-bwix1/dronedataset-n1dlr Satellite : https://universe.roboflow.com/yolo-k8awx/arirang-tljec	Drone : https://universe.roboflow.com/coastal-semantic-dynamic-localization/kahana-bay Satellite : https://www.kaggle.com/datasets/balraj98/deepglobe-land-cover-classification-dataset	Drone : https://universe.roboflow.com/coastal-semantic-dynamic-localization/kahana-bay

Résolution	Drone : 640×640 px Satellite : 1024×1024px	Drone : 2448×2448 px Satellite : 4056 × 3040 px	4056 × 3040 px
Classes	Drone : • Voiture • moto Satellite : • voiture • avion	Drone : • voiture • pavement • eau • végétation Satellite : • sol • végétation • bâtiment • eau	Drone : • voiture • pavement • eau • végétation
Volume	Drone : 447 images Satellite : 1975 images	Drone : 718 images Satellite : 1146 images	Drone : 718 images
Répartition	Drone : 70% train (365) 20% val (53) 10% test (29) Satellite : 70% train () 20% val () 10% test ()	Drone : 70% train (498) 20% val (136) 10% test (84) Satellite : 70% train (803) 20% val (243) 10% test (100)	70% train (498) 20% val (136) 10% test (84)
Format d'annotation	Yolov8n	Semantic segmentation mask	COCO JSON
Modèle utilisé	YOLOv8	U-Net	Mask R-CNN

2. Environnement de travail et outils utilisés :

2.1 Bibliothèques et frameworks (PyTorch, Ultralytics, etc.) :

Le projet a été réalisé en **Python 3.12**, sans environnement virtuel, avec l'installation directe des bibliothèques via **pip**. Il s'appuie sur un ensemble de

frameworks puissants et largement utilisés en vision par ordinateur et deep learning.



➤ **Bibliothèques principales utilisées :**

 **PyTorch** : bibliothèque principale pour la conception et l'entraînement des modèles de segmentation (**U-Net**, **Mask R-CNN**). Modules utilisés : torch, torch.nn, torch.utils.data, torchvision.models. PyTorch a permis de construire les réseaux neuronaux, gérer les optimisations, calculer les fonctions de perte (ex. CrossEntropy, Dice), et exécuter l'entraînement sur CPU et GPU selon les machines disponibles.



Ultralytics YOLOv8 [4] : framework prêt à l'emploi pour la détection d'objets. Utilisé via le package ultralytics, avec des commandes comme `yolo task=detect model=yolov8n.pt`. Permet d'entraîner facilement un modèle YOLOv8 à partir d'un dataset annoté au format YOLO, avec génération automatique des métriques (confusion matrix, IoU, PR curves).



OpenCV (cv2**)** : utilisé pour des tâches fondamentales de traitement d'image (lecture, redimensionnement, conversion de couleurs, tracé de boîtes). Sert aussi à la post-visualisation des résultats (masques, prédictions).



NumPy : indispensable pour les opérations sur les tableaux, la gestion des masques binaires, les conversions entre formats (OpenCV $\leftrightarrow$ Pillow), et les traitements vectoriels rapides.



Matplotlib : utilisé pour l'affichage des courbes de performance (IoU, Dice, perte), ainsi que pour visualiser les résultats de segmentation/détection pendant et après l'entraînement.



Pillow (PIL**)** : utilisé en complément d'OpenCV pour charger, transformer ou enregistrer des images, notamment dans les processus d'augmentation, de conversion et d'affichage.

- ❖ Aucune gestion d'environnement virtuel n'a été utilisée ; toutes les bibliothèques ont été installées directement avec **pip** sur l'installation locale de Python.



2.2 Outils d'annotation et traitement (LabelImg, Roboflow, QGIS...)

:

Outils exploités :



LabelImg

LabelImg : outil open source léger pour l'édition et la vérification des annotations au format YOLO. Utilisé ici pour visualiser ou corriger les fichiers .txt associés aux images drones, et ajuster les boîtes lorsque nécessaire.



Roboflow [5] : plateforme utilisée

pour :

- Importer et organiser des jeux de données annotés,
- Appliquer des prétraitements standards (resize, flip, rotation, split train/val/test),
- Exporter les données vers différents formats (YOLOv5/YOLOv8, COCO JSON),
- Générer automatiquement des ensembles de données augmentés pour renforcer la robustesse des modèles. C'est un outil central dans la gestion du dataset.



Kaggle [6] : plateforme en ligne utilisée à plusieurs niveaux dans ce projet.

Elle a permis :

- D'explorer des datasets open-source liés aux images de drones et à la segmentation.
- De comparer les structures de datasets avec celui utilisé ici.
- D'inspirer certains choix de prétraitements et de formats d'annotation (comme COCO JSON ou YOLOv8).
- D'entraîner des modèles directement sur l'infrastructure de Kaggle, en tirant parti des notebooks avec GPU gratuits, ce qui a facilité les expérimentations sans configuration locale complexe.

2.3 Configuration matérielle et logicielle :

Le projet a été réalisé en alternance sur deux postes de travail disposant de configurations différentes selon les besoins (entraînement, annotation, visualisation) :

- **Ordinateur 1** – Entraînement (avec GPU)
 - Système : Windows 11
 - Processeur : CPU avec GPU dédié (NVIDIA)
 - RAM : 16 Go
 - Utilisation : exécution des modèles lourds comme U-Net et YOLOv8, entraînement sur GPU pour accélérer le traitement.
- **Ordinateur 2** – Annotation et prétraitement (sans GPU)
 - Système : Windows 10

- Processeur : CPU uniquement
- RAM : 8 Go
- Utilisation : annotation, préparation des données, tests légers, visualisation des résultats.
- **Kaggle** – Plateforme d’entraînement en ligne
 - Système : Basé sur Linux (notebooks en ligne)
 - Processeur : Accès à des CPU/GPU via l’infrastructure cloud de Kaggle
 - RAM : Jusqu’à 13 Go selon l’environnement activé
 - Utilisation : entraînement de modèles **U-Net**, **YOLOv8** et **Mask R-CNN** dans des notebooks avec GPU gratuit, idéal pour tester rapidement différentes configurations et contourner les limites matérielles locales.

3. Mise en œuvre des modèles de détection et segmentation :

3.1 Choix et paramétrage des modèles YOLOv8, U-Net, Mask R-CNN :

Trois architectures de deep learning ont été mises en œuvre, chacune choisie pour sa pertinence selon le type de tâche et de données :

- **YOLOv8** : utilisé pour la détection rapide d’objets (véhicules, motos, etc.) sur les images drones. Ce modèle est particulièrement efficace en temps réel et adapté aux scènes dynamiques.
- **U-Net** : appliqué à la segmentation sémantique sur des images satellites, pour la classification pixel par pixel de zones géographiques (sols, routes, végétation...).

- **Mask R-CNN** : utilisé ici également pour la segmentation sémantique, malgré son architecture initialement conçue pour la segmentation d'instance, afin de comparer ses performances avec U-Net sur des images drones statiques.

Chaque modèle a été entraîné à l'aide de paramètres personnalisés, ajustés en fonction des capacités matérielles (CPU ou GPU) et du type de données. Les hyperparamètres comme le taux d'apprentissage (learning rate), la taille de batch (batch size) et le nombre d'époques ont été adaptés selon le modèle et la taille du dataset. Les configurations ont été testées de manière itérative jusqu'à l'obtention de résultats stables.

3.2 Méthodologie d'entraînement et validation croisée :

Les jeux de données ont été divisés en 70 % pour l'entraînement, 20 % pour la validation et 10 % pour les tests. Une validation croisée 5-fold a été appliquée pour mesurer la robustesse des modèles. Les optimisations ont été menées avec l'algorithme **Adam**, en utilisant une fonction de perte composite (IoU + CrossEntropy).

3.3 Adaptation aux caractéristiques des images satellites et drones :

Des ajustements spécifiques ont été appliqués en fonction du type d'image et de la résolution :

- **Pour les images satellites** : les images ont été redimensionnées à des tailles standard (ex. 512×512 ou 640×640) compatibles avec les modèles, puis normalisées canal par canal (RGB) pour assurer une bonne convergence pendant l'entraînement.
- **Pour les images drones** : certaines images ont nécessité une correction d'orientation ou de cadrage, et des techniques d'augmentation de données ont été appliquées (flip horizontal, rotation, zoom aléatoire) afin de simuler des variations de scène et renforcer la capacité de généralisation des modèles.

Ces adaptations ont permis de rendre les données compatibles avec les exigences des architectures de deep learning utilisées, tout en améliorant leur robustesse face à la diversité des scènes observées

4. Résultats et Évaluation :

4.1 Résultats par modèle et par type d'image :

Les tests réalisés ont permis de comparer les performances des modèles sur des images issues de drones et de satellites. Voici les observations principales :

4.1.1 YOLOv8 – Détection sur images drone et satellite

Le modèle YOLOv8 a été utilisé pour détecter des objets visibles dans des images issues de drones et de satellites. Grâce à sa rapidité et sa capacité à fonctionner en temps réel, il a montré des performances satisfaisantes, même dans des environnements complexes




Figure 19 : image prise par drone




Figure 20 : Détection avec YOLOv8 sur l' image

- ❖ L'image montre une rue avec plusieurs véhicules à moteur. YOLOv8 a détecté 3 voitures et 3 motos avec des scores de confiance élevés (allant jusqu'à 0.93).

Le temps d'inférence par image était d'environ 243 ms, avec 11 ms de pré-traitement et 13 ms de post-traitement sur une image de dimension 640×640.




Figure 21 :image prise par satellite



Figure 22 : Résultat YOLOv8 sur l' image

- ❖ Cette image satellite d'un aéroport a permis de détecter 9 avions et 7 petites voitures, avec des scores supérieurs à 0.70 pour la majorité des objets.

4.1.2 Mask R-CNN – Segmentation sémantique sur image drone

Le modèle Mask R-CNN a été utilisé dans ce projet pour réaliser de la segmentation sémantique sur une image captée par drone. Contrairement à sa vocation initiale (segmentation d'instance), il a été ici exploité pour classer les pixels selon quatre catégories visuelles :

- car (voiture),
- pavement (revêtement/sol urbain),
- water (zone aquatique),
- vegetation (végétation ou petits buissons).




Figure 23 : Résultat de segmentation sémantique avec Mask R-CNN sur image drone

- ❖ Le modèle a bien réussi à identifier les différentes régions de l'image : les véhicules sont détectés avec des masques rouges précis, la mer est couverte d'un masque bleu homogène, et les éléments naturels (végétation) sont également isolés en vert de plus le pavement a un masque gris.

4.1.3 U-Net – Segmentation sémantique sur images satellites

Le modèle U-Net a été utilisé pour effectuer une segmentation sémantique pixel par pixel sur des images satellites. Il a été entraîné pour identifier quatre classes géospatiales principales :

- soil (sol),
- tree (végétation/arbre),
- water (eau),
- home (bâtiment/maison).

U-Net a produit des résultats solides, notamment pour les zones homogènes comme les rivières et les espaces végétalisés. La segmentation a été testée sur une image issue du dataset ainsi que sur une image hors dataset pour évaluer la généralisation du modèle.




Figure 24 :Résultat U-Net sur image satellite du dataset

- ❖ La prédiction reproduit bien les zones d'eau, de végétation , les surfaces de sol,et les maisons avec une bonne cohérence spatiale par rapport au masque réel.




Figure 25 :Résultat U-Net sur image Drone du dataset

- ❖ Le modèle a bien réussi à identifier les différentes régions de l'image : les véhicules sont détectés avec des masques rouges précis, la mer est couverte d'un masque bleu homogène, et les éléments naturels (végétation) sont également isolés en vert de plus le pavement a un masque gris

❖ les performances (IoU, Dice coefficient)

Pour évaluer la qualité de segmentation du modèle **U-Net**, deux métriques fondamentales ont été utilisées :

- **IoU (Intersection over Union) :**

Elle mesure le chevauchement entre la prédiction du modèle et la vérité terrain. Plus l'IoU est élevé, plus la prédiction est précise.

$$IoU = \frac{|\text{Prédiction} \cap \text{Vérité terrain}|}{|\text{Prédiction} \cup \text{Vérité terrain}|}$$

- **Dice coefficient :**

Similaire à l'IoU mais plus sensible aux erreurs dans les petites régions. Elle est particulièrement adaptée aux tâches de segmentation sémantique.

$$Dice = \frac{2 \cdot |\text{Prédiction} \cap \text{Vérité terrain}|}{|\text{Prédiction}| + |\text{Vérité terrain}|}$$


Notes :

- Les deux métriques donnent des valeurs entre 0 (aucun recouvrement) et 1 (chevauchement parfait).
- Le **Dice** est souvent plus indulgent dans les cas où les objets sont petits (c'est pourquoi il est préféré en segmentation médicale par exemple).
- Ces fonctions supposent que y_true et y_pred sont des **masques binaires** (numpy.ndarray de 0 et 1).


Ces métriques ont été appliquées **uniquement au modèle U-Net**, car il s'agit du seul modèle dédié exclusivement à la segmentation dans ce projet.

Les modèles YOLOv8 et Mask R-CNN, eux, n'ont pas été évalués avec ces indicateurs dans cette étude.

❖ Dataset d'Images satellitaires



❖ Dataset d'Images drone



Conclusion et Perspectives :

Ce projet a démontré la faisabilité et l'efficacité d'une approche hybride combinant vision par ordinateur et apprentissage profond pour l'analyse d'images géospatiales. En exploitant des données issues de satellites (comme

celles de Sentinel ou Kaggle) et de drones (via la plateforme Roboflow), nous avons mis en œuvre trois architectures de deep learning : YOLOv8 pour la détection rapide d'objets, U-Net pour la segmentation sémantique, et Mask R-CNN pour la segmentation fine. Chacun de ces modèles a été sélectionné et configuré selon les besoins spécifiques des tâches à accomplir et la nature des images traitées.

Malgré ces résultats prometteurs, certaines limites ont été identifiées. La qualité des annotations, le déséquilibre entre les classes, ainsi que les contraintes matérielles (notamment pour l'entraînement sur des machines sans GPU) ont parfois impacté la précision des prédictions. L'analyse comparative des résultats nous a permis de mieux comprendre les forces et faiblesses de chaque modèle, et a mis en évidence la pertinence d'une approche multi-modèles adaptée aux différents types de données (satellite vs drone) et d'objectifs (cartographie globale vs inspection fine).

Pour les perspectives futures, plusieurs pistes d'amélioration s'ouvrent. D'une part, l'intégration de modèles plus récents, tels que SAM (Segment Anything Model) ou Mask2Former, pourrait améliorer la précision de la segmentation grâce à une meilleure exploitation du contexte spatial. D'autre part, l'automatisation du processus d'annotation à l'aide de techniques d'active learning permettrait de réduire considérablement le coût humain et de renforcer la cohérence des jeux de données. En outre, l'ajout de capteurs multispectraux ou thermiques aux dispositifs de capture permettrait d'enrichir les données et d'améliorer la détection de certains objets spécifiques (zones humides, anomalies thermiques...). Enfin, une approche multi-capteurs combinant simultanément les images drone et satellite pourrait offrir une couverture plus large et plus précise, notamment pour des applications à la fois locales et régionales.

En résumé, ce projet constitue une base solide pour le développement de systèmes intelligents de traitement d'images géospatiales, avec des perspectives applicables à l'agriculture de précision, la cartographie urbaine, la surveillance environnementale ou encore la gestion des risques.

Références bibliographiques

1. Ronneberger, O., Fischer, P., & Brox, T. (2015).
U-Net: Convolutional Networks for Biomedical Image Segmentation.
[arXiv:1505.04597](https://arxiv.org/abs/1505.04597)
2. He, K., Gkioxari, G., Dollár, P., & Girshick, R. (2017).
Mask R-CNN.
[arXiv:1703.06870](https://arxiv.org/abs/1703.06870)
3. Redmon, J., & Farhadi, A.
YOLO: Real-Time Object Detection.
[Lien vers le site officiel](https://pjreddie.com/darknet/yolo/)
4. Ultralytics.
YOLOv8 by Ultralytics.
<https://github.com/ultralytics/ultralytics>
5. Roboflow.
Roboflow: Annotate, Train, Deploy.
<https://roboflow.com>
6. Kaggle.
Satellite Datasets on Kaggle.
<https://www.kaggle.com/datasets?search=satellite>
7. CNES, Copernicus, UN-SPIDER, IGN (2023).
Données satellitaires et géospatiales.
<https://www.un-spider.org>
8. Architecture YOLOv8
Diagramme :
[ResearchGate – YOLOv8 network structure](https://www.researchgate.net/publication/354111111)

9. Architecture Mask R-CNN

Diagramme :

[ResearchGate – Structure of Mask R-CNN](#)

10. Architecture U-Net

Diagramme :

[Google Images – U-Net](#)